

Universidad del Gran Rosario

Área de Tecnología y Negocios



PROYECTO DE TRABAJO FINAL

Seminario de Trabajo Final

Detección temprana de depresión mediante procesamiento de lenguaje natural y aprendizaje automático

Autores:

Tec. Univ. Giuliano Crenna – **DNI 43.841.488**

Tec. Univ. Bruno Emmanuel Pace – **DNI 43.127.593**

Lugar: Rosario, Santa Fe, Argentina

Resumen

En el presente trabajo se propone el desarrollo de un sistema de detección temprana de depresión a partir del análisis automático de texto, empleando técnicas de Procesamiento de Lenguaje Natural (PLN) y aprendizaje automático supervisado. La motivación central es que los trastornos depresivos constituyen uno de los problemas de salud mental más prevalentes a nivel global —la Organización Mundial de la Salud estima que aproximadamente un 5,7 % de los adultos los padece [1]— y que una proporción significativa de personas expresa indicadores lingüísticos de malestar psicológico en redes sociales y otros canales digitales antes de buscar ayuda profesional [2, 3]. El trabajo plantea construir un corpus en español, entrenar y comparar modelos de referencia (TF-IDF + regresión logística, SVM, BETO) y un modelo transformer afinado para clasificar usuarios con probabilidad alta, media o baja de presentar sintomatología depresiva, prestando especial atención a la interpretabilidad de los marcadores lingüísticos identificados. Como resultado esperado se obtendrá un modelo reproducible, una caracterización de marcadores en español y una evaluación crítica del estado del arte en la materia.

Palabras clave: Procesamiento de Lenguaje Natural; Depresión; Detección Temprana; Aprendizaje Automático; BERT; Salud Mental; Redes Sociales; Español.

Temática de interés en Ciencia de Datos: Aprendizaje Automático Supervisado y PLN aplicado a salud.

1. Problemática observada

La depresión es un trastorno del estado de ánimo cuya carga mundial sigue en aumento. Las cifras más recientes de la Organización Mundial de la Salud indican que en 2021 alrededor de 332 millones de personas padecían algún trastorno depresivo, que menos del 10 % de quienes lo sufren reciben un tratamiento mínimamente adecuado y que la prevalencia es aproximadamente 1,5 veces mayor en mujeres que en hombres [1, 4]. La detección tardía se asocia a peor pronóstico, mayor riesgo de suicidio y mayor coste sociosanitario [5].

En paralelo, el uso masivo de redes sociales y mensajería instantánea ha generado un volumen sin precedentes de texto en lenguaje espontáneo en el que muchas personas manifiestan, de forma más o menos explícita, marcadores lingüísticos asociados a estados depresivos: uso elevado de pronombres en primera persona del singular, vocabulario absolutista (“siempre”, “nada”, “nunca”), lenguaje absolutista, mayor densidad de emociones negativas, descenso del contenido social y patrones de actividad temporal alterados [6, 5, 7, 8]. Esta huella lingüística puede aprovecharse como una señal *temprana y no intrusiva* para alertar a un potencial afectado, sin reemplazar el diagnóstico clínico [9].

El problema, por tanto, no es sólo clínico sino también computacional y social: ¿es

viable construir un modelo que, a partir de texto escrito en español, identifique perfiles con alta probabilidad de presentar sintomatología depresiva, manteniendo una precisión razonable, respetando la privacidad del usuario y siendo interpretable por profesionales de la salud mental?

2. Hipótesis de investigación

Hipótesis principal. *Es posible desarrollar un modelo de aprendizaje automático supervisado que, a partir de texto escrito en lengua española y características lingüísticas extraídas mediante técnicas de Procesamiento de Lenguaje Natural, clasifique usuarios con probabilidad alta, media o baja de presentar sintomatología depresiva, con un rendimiento (medido en F1-score sobre la clase positiva) superior al de los modelos de referencia clásicos.*

Hipótesis secundarias.

1. La combinación de marcadores lingüísticos clásicos (LIWC, polaridad, n-gramas) con embeddings contextuales generados por BETO [10] mejorará la detección respecto a cualquier técnica utilizada de forma aislada.
2. El ajuste fino (*fine-tuning*) de BETO sobre un corpus en español depresivo/no depresivo obtendrá mejor *F1-score* que los modelos Transformer multilingües genéricos [11].
3. La interpretabilidad de los marcadores (analizada mediante SHAP [12] o LIME [8]) será consistente con los hallazgos psicológicos previos sobre marcadores depresivos (primera persona singular, lenguaje absolutista, emociones negativas).

3. Objetivo general

Desarrollar y evaluar experimentalmente un sistema de detección temprana de depresión en usuarios hispanohablantes a partir del análisis de texto, mediante técnicas de Procesamiento de Lenguaje Natural y modelos de aprendizaje automático supervisado, con énfasis en la interpretabilidad y la replicabilidad.

4. Objetivos específicos

1. Construir o buscar un corpus en español (alternativamente en inglés) para la detección de depresión, combinando fuentes públicas (*MentalRiskES* [11] e *Leis et al.* [5, 9]).
2. Realizar un análisis exploratorio del corpus que caracterice los marcadores lingüísticos diferenciales entre las clases (depresivo, moderado, control).
3. Entrenar y comparar un *baseline* clásico (TF-IDF + Regresión Logística/SVM), un modelo BETO [10] ajustado y un modelo híbrido (LIWC + embeddings).
4. Aplicar técnicas de inteligencia artificial explicable (XAI) como SHAP y LIME para identificar los marcadores que más influyen en la predicción.
5. Evaluar el rendimiento con métricas estándar (*accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC) y discutir los errores y sesgos.
6. Redactar un informe con el código, los datos y los resultados para asegurar la reproducibilidad del trabajo.

5. Antecedentes

El campo de la detección automática de depresión a partir de texto se ha consolidado en la última década. Una revisión sistemática reciente [2] identificó 123 estudios primarios que aplican técnicas de PLN y aprendizaje automático para identificar depresión a partir de habla o texto escrito; los autores sintetizaron 43 estudios y obtuvieron una *accuracy* agrupada de 0,80 (IC 95 %: 0,77–0,83), con diferencias significativas según la fuente de texto, el idioma y la familia de clasificadores utilizada.

Métodos clásicos. Los primeros trabajos (2013–2018) utilizaron extracción manual de características (LIWC [9], n-gramas, BoW, TF-IDF) combinadas con clasificadores como SVM, Naïve Bayes, Regresión Logística y Random Forest. En el ámbito hispanohablante destaca el estudio de Leis et al. [5], que construyó tres corpus de *tweets* en español y demostró que los usuarios con depresión modifican tanto el lenguaje como el patrón temporal de publicación (más actividad nocturna, mayor frecuencia). La tesis doctoral de Leis [9] amplía ese trabajo con un lexicón abierto en español para detección de depresión en Twitter.

Deep learning y transformers. A partir de 2019, los modelos basados en transformers desplazaron a los enfoques clásicos. BERT, RoBERTa y *MentalBERT* —variante de BERT pre-entrenada sobre contenido de salud mental en Reddit [6]— alcanzan precisiones de 0,90 a 0,99 en tareas de clasificación binaria sobre Twitter y Reddit [13, ?, 14]. Para español, el

modelo BETO [10] ofrece embeddings contextualizados entrenados con la técnica *Whole Word Masking* sobre un gran corpus en castellano, con mejores resultados que *mBERT* en tareas de PLN en español.

Datasets. Los recursos de referencia son:

- **eRisk** (CLEF) [15]: corpus de usuarios de Reddit con depresión autoinformada.
- **DAIC-WOZ** [16]: entrevistas clínicas semiestructuradas con anotación PHQ-8, usado en los retos AVEC.
- **MentalRiskES** (IberLEF 2023 / LREC 2024) [11]: 45 000 mensajes de Telegram en español de 1 300 usuarios, con anotación crowdsourcing para depresión, ansiedad y trastornos alimentarios.
- **Leis et al.** [5]: corpus de *tweets* en español, dividido en usuarios depresivos (n=90), tweets depresivos (n=1 000) y controles (n=450).
- **Reddit Self-reported Depression Diagnosis** (RSDD) [17]: 116 000 usuarios etiquetados por autoinforme.

Tareas compartidas. El workshop CLEF *eRisk* [15] y el compartido *MentalRiskES* [11] han estandarizado protocolos de evaluación temprana, frecuentemente basados en BDI-II o en el propio autoinforme.

Huecos identificados. Aunque la producción científica es abundante, la mayor parte de los estudios se concentran en inglés; los trabajos en español son aún escasos, pocos utilizan modelos específicos de la lengua (BETO, MarIA, RoBERTa-BNE) y la reproducibilidad se ve limitada por la falta de código y datos abiertos [18, 19]. .

6. Metodología

La investigación se desarrollará en seis etapas secuenciales con criterios de calidad y reproducibilidad (versionado con `git`, *seeds* fijos, registro de experimentos con MLflow o Weights & Biases).

Etapas 1 – Revisión bibliográfica. Búsqueda sistemática en Scopus, Web of Science, IEEE Xplore, ACL Anthology, arXiv y Google Scholar, con descriptores en español e inglés: *depression detection*, *early risk detection*, *mental health NLP*, *MentalRiskES*, *BETO depression*, *detección depresión PLN*. Se identificarán los trabajos más citados y los publicados entre 2022 y 2025.

Etapas 2 – Construcción del corpus. Se combinarán:

- El corpus **MentalRiskES** [11] (1 300 usuarios, 45 000 mensajes de Telegram, anotación de depresión, ansiedad y TCA).
- El corpus de **Leis et al.** [5] (tweets en español con perfiles depresivos, tweets depresivos y controles).
- Datos públicos en Kaggle/Reddit (*Suicide and Depression Detection* y derivados) previa traducción/filtrado al español cuando sea posible.

Se aplicará una capa de anonimización (eliminación de menciones, URLs, *handles* y metadatos).

Etapas 3 – Preprocesamiento y EDA. Tokenización, lematización y limpieza con *spaCy*; cálculo de descriptores (longitud, número de pronombres en primera persona, densidad de palabras negativas/absolutistas, polaridad con *SentimentIntensityAnalyzer* y conteos LIWC en su versión en español [9]). Se visualizarán distribuciones y nubes de palabras por clase.

Etapas 4 – Modelado. Se entrenarán y compararán:

1. **Baseline clásico:** TF-IDF (1–2 gramas) + Regresión Logística y SVM lineal.
2. **Modelo BETO:** ajuste fino de `dccuchile/bert-base-spanish-wwm-cased` [10] durante 3–5 épocas, con *learning rate* de 2×10^{-5} , *batch size* 16 y *early stopping* sobre *F1* de validación.
3. **Modelo híbrido:** concatenación de embeddings BETO + vector LIWC + rasgos temporales, seguido de una capa densa.
4. (Opcional) **MentalRiskES BERT finetuned** y **XLM-RoBERTa** como referencia multilingüe.

Etapas 5 – Evaluación. Validación cruzada estratificada (5 pliegues) y, cuando aplique, partición *user-level* para evitar fuga de datos. Métricas: *accuracy*, *precision*, *recall*, *F1-score* (macro y ponderado) y AUC-ROC. Se reportará matriz de confusión y se discutirán falsos negativos (riesgo clínico).

Etapas 6 – Interpretabilidad. Aplicación de SHAP y LIME sobre el mejor modelo para identificar los marcadores que más contribuyen a la predicción. Se contrastarán los marcadores identificados con los reportados en la literatura psicológica (e.g. Rude et al., 2004 [6]).

7. Recursos disponibles

- **Datos:** corpus públicos *MentalRiskES*, *Leis et al.*, *RSDD*, *DAIC-WOZ* (acceso académico) y *Reddit Self-reported Depression* en Kaggle.
- **Hardware:** equipo personal con GPU dedicada (NVIDIA RTX 3060 o superior); alternativamente, Google Colab Pro o Kaggle Notebooks (GPU T4).
- **Software:** Python 3.11, JupyterLab, *pandas*, *numpy*, *scikit-learn*, *spaCy*, *transformers* (Hugging Face), *torch*, *shap*, *lime*, *mlflow*, *matplotlib*, *seaborn*, *NLTK*.
- **Modelos preentrenados:** BETO (*dccuchile/bert-base-spanish-wwm-cased/uncased*) [10], RoBERTa-BNE, XLM-RoBERTa.
- **Conectividad:** acceso a Internet estable.
- **Asesoramiento:** dirección de la cátedra y, eventualmente, consulta con profesionales de psicología clínica para la validación ética y clínica de los marcadores.

8. Impacto esperado

Impacto científico. Aportar un estudio reproducible en un área con predominio anglosajón [18]. El código, los datos y los modelos entrenados se publicarán en GitHub bajo licencia MIT, facilitando la comparación con trabajos futuros. La caracterización de marcadores en español puede ser insumo para nuevos lexicones o herramientas de PLN clínico.

Impacto social y sanitario. La depresión tiene fuerte prevalencia y elevada carga de discapacidad [1]. Un sistema de alerta temprana podría canalizar usuarios en riesgo hacia servicios profesionales, especialmente en poblaciones con menor acceso a atención presencial, sin reemplazar el diagnóstico clínico [5, 9]. El sistema se plantea como una herramienta de *triaje* y sensibilización, no de diagnóstico.

Impacto tecnológico. Adaptación al español de técnicas de NLP clínico validadas en inglés. Combinación de modelos transformer específicos (BETO) con interpretabilidad post-hoc (XAI) para acercar la IA a profesionales de salud mental. Posibilidad de extensión a otros trastornos (ansiedad, ideación suicida) y a otras lenguas cooficiales (catalán, gallego, euskera).

Impacto formativo. Integración de conocimientos de PLN, aprendizaje automático, ética en datos y salud mental, en línea con la formación del grado. Trabajo en equipo interdisciplinario entre los autores.

Consideraciones éticas. Se seguirán las recomendaciones de la [2] y [9]: uso exclusivo de datos públicos o anonimizados, transparencia sobre limitaciones, *opt-out* de usuarios cuando sea técnicamente posible, validación previa con profesionales de salud mental y declaración explícita de que el sistema *no reemplaza* el diagnóstico clínico.

9. Cronograma

El trabajo se planifica en cinco meses, con actividades que se solapan en el tiempo. A continuación se presenta el diagrama de Gantt correspondiente (Figura ??).

Actividades	Meses	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5
Revisión bibliográfica						
Elaboración de antecedentes						
Preparación de algoritmos						
Revisión de los conjuntos de datos						
Elaboración de modelos						
Elaboración de conclusiones						
Elaboración de informe						
Presentación de resultados						

Figura 1: Diagrama de Gantt del proyecto. Las barras representan la duración planificada de cada actividad; los rombos naranjas son los hitos principales y las flechas indican relaciones de precedencia.

10. Índice propuesto

1. Introducción

- 1.1. Antecedentes y motivación
- 2.2. Planteamiento del problema
- 3.3. Hipótesis de trabajo
- 4.4. Objetivos (general y específicos)

2. Marco teórico y estado del arte

- 1.1. La depresión: definición clínica y epidemiológica
- 2.2. Lingüística de la depresión: marcadores psicolingüísticos
- 3.3. Procesamiento de Lenguaje Natural y transformers
- 4.4. Aprendizaje automático supervisado y explicable

3. Datos

- 1.1. Revisión de corpus públicos (*MentalRiskES*, *Leis et al.*, *eRisk*, *DAIC-WOZ*)
- 2.2. Construcción y anonimización del corpus propio
- 3.3. Análisis exploratorio de datos (EDA)

4. Metodología

- 1.1. Preprocesamiento y extracción de características
- 2.2. Líneas base clásicas (TF-IDF + LR/SVM)
- 3.3. Ajuste fino de BETO
- 4.4. Modelo híbrido (embeddings + LIWC)
- 5.5. Protocolo de evaluación y métricas
- 6.6. Interpretabilidad (SHAP/LIME)
5. **Resultados y discusión**
 - 1.1. Comparación de modelos
 - 2.2. Análisis de errores y sesgos
 - 3.3. Limitaciones y amenazas a la validez
6. **Conclusiones y trabajo futuro**
7. **Bibliografía**
8. **Anexos** (código, particiones, prompts, hojas de consentimiento)

Referencias

- [1] World Health Organization, “Depressive disorder (depression) – fact sheet,” 2025. Accessed: 2025-08-25.
- [2] A. Le Glaz and et al., “Language-based detection of depression with machine learning: systematic review and meta-analysis,” *npj Digital Medicine*, vol. 9, pp. 1–15, 2026.
- [3] R. A. Calvo and et al., “Screening for depression using natural language processing: A systematic review,” *Journal of Medical Internet Research*, 2024.
- [4] World Health Organization, “World mental health today: latest data,” 2025.
- [5] A. Leis, F. Ronzano, H. Saggion, L. I. Furlong, and F. Sanz, “Detecting signs of depression in tweets in spanish: Behavioral and linguistic analysis,” *Journal of Medical Internet Research*, vol. 21, no. 6, p. e14199, 2019.
- [6] S. Ji, X. Li, L. Sun, H. Wang, W. Peng, T. McMann, and F. Scalzo, “Early depression detection with transformer models: Mentalbert and roberta,” in *Proceedings of the 56th Hawaii International Conference on System Sciences (HICSS)*, pp. 3379–3388, 2023.
- [7] A. Le Glaz and et al., “Natural language processing applied to mental illness detection: a narrative review,” *npj Digital Medicine*, vol. 5, no. 1, p. 86, 2022.
- [8] S. Ahmad and et al., “Explainable ai-driven depression detection from social media using nlp and machine learning,” *Frontiers in Artificial Intelligence*, vol. 8, 2025.
- [9] A. Leis, *Detection of signs of depression in tweets in Spanish*. PhD thesis, Universitat Pompeu Fabra, 2019.
- [10] J. P. Cáceres and et al., “Beto: The pre-trained bert model for spanish (dccuchile/bert-base-spanish-wwm-uncased / -cased).” Hugging Face Model Hub, 2020. DCC Universidad de Chile.
- [11] A. M. Mármol-Romero, A. Moreno-Muñoz, J. H. Álvez, D. Tomás, M. García-Vega, M. Á. García-Cumbreras, A. Montejo-Ráez, L. A. Ureña-López, and M. T. Martín-Valdivia, “Mentalrises: A new corpus for early detection of mental disorders in spanish,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 10104–10115, 2024.

- [12] M. A. Yáñez Soffia, “Análisis sobre modelos predictores de depresión mediante la interpretación de lenguaje natural a partir de textos usando machine learning,” Master’s thesis, E.T.S. de Ingenieros Informáticos, Universidad Politécnica de Madrid, 2023.
- [13] M. Saeedi and et al., “Applications of transformer-based language models for depression detection: A scoping review,” *Journal of Information Security and Safety*, 2024.
- [14] A. Amanat and et al., “Analyzing depression in college students using nlp and a hybrid roberta–gru framework,” *Journal of Healthcare Engineering*, 2025.
- [15] D. E. Losada, F. Crestani, and J. Parapar, “erisk 2017: Clef lab on early risk prediction on the internet: Experimental foundations,” in *Experimental IR Meets Multilinguality, Multimodality, and Interaction – 8th International Conference of the CLEF Association, CLEF 2017*, 2017.
- [16] J. Gratch, R. Artstein, G. Lucas, G. Stratou, S. Scherer, A. Nazarian, R. Wood, J. Boberg, D. DeVault, S. Marsella, D. Traum, S. Rizzo, and L.-P. Morency, “The distress analysis interview corpus of human and computer interviews,” tech. rep., University of Southern California, Institute for Creative Technologies, 2014.
- [17] S. Bucuram, “Datasets for depression modeling in social media: An overview.” arXiv preprint arXiv:2503.21513, 2025. Repositorio: <https://github.com/bucuram/depression-datasets-nlp>.
- [18] R. S. Alemán Acuña, E. Pereira Montiel, E. A. Torres Silva, and D. A. Montoya Arenas, “Uso del procesamiento de lenguaje natural en la salud mental: Revisión de alcance,” *Revista Iberoamericana de Psicología*, 2024.
- [19] A. Vásquez and et al., “Análisis del lenguaje natural para la identificación de alteraciones mentales en redes sociales: Una revisión sistemática de estudios,” *Revista de Investigación en Tecnologías de la Información*, 2024.